


機械学習

機械学習

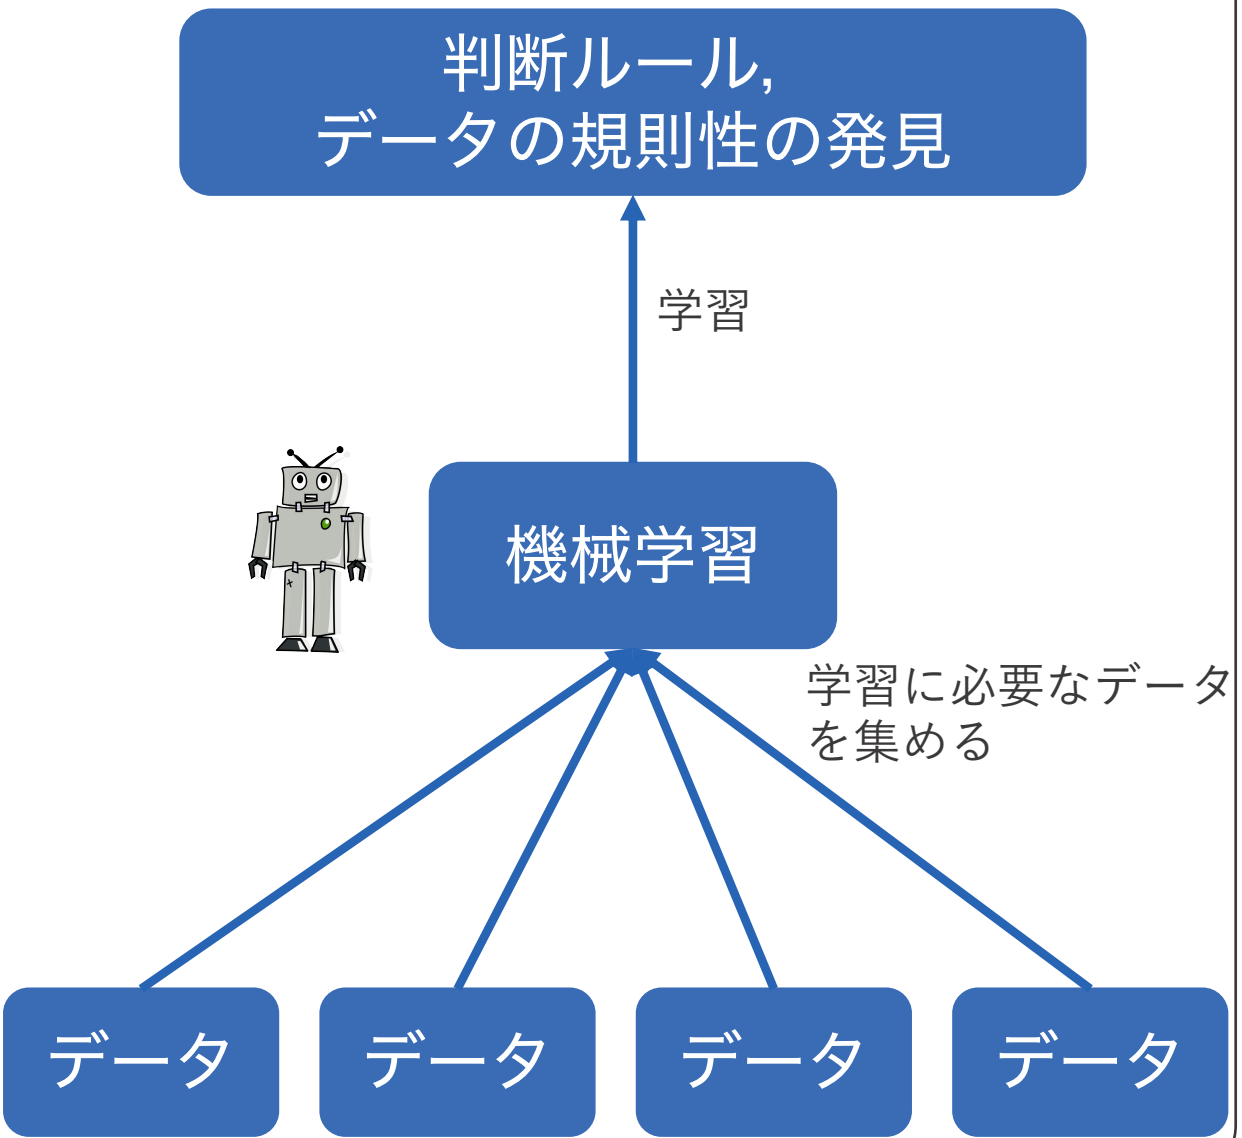
- 機械に学習させる手法を取り扱う学問領域およびその技術.
- 特に確率・統計に立脚したものを統計的機械学習という（現在は単に機械学習といえばこれ）.
- いわゆる人工知能で使われる技術. データマイニングでも使われている.



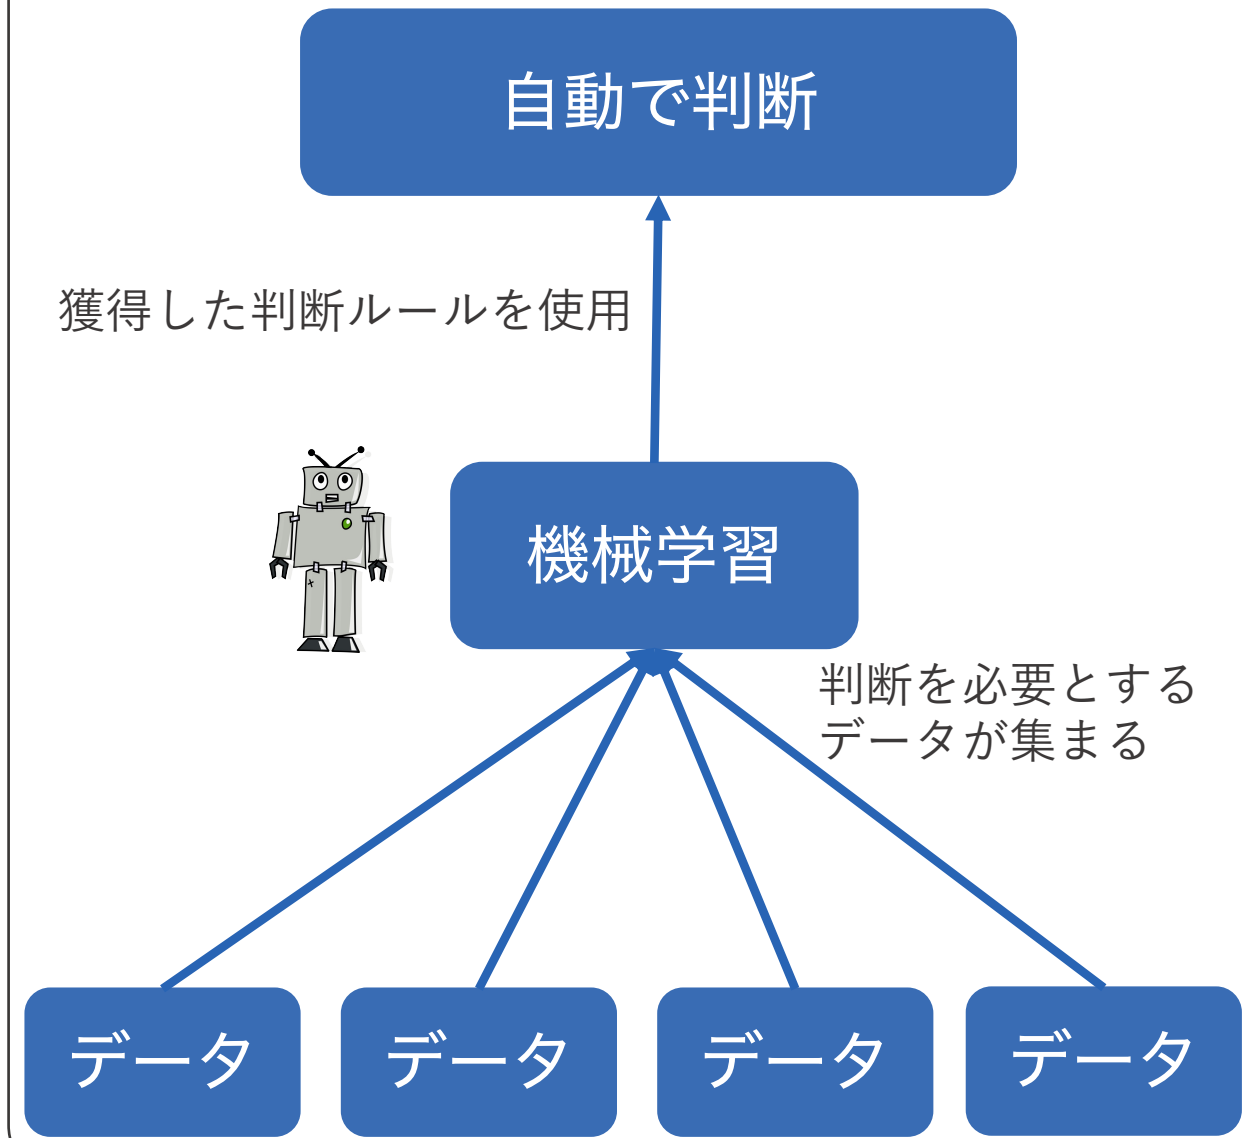
例えば、機械学習の手法を用いて、機械が数字と書かれた画像を数字であると判断するように学ばせる。機械は入力とラベルの間の規則性を学習の過程で見出す（かもしれない）。

■ 学習と判断

学習




判断



機械学習で何ができる

- IBMの質問応答システム

- 2011年アメリカのクイズ番組で人間と対決し勝利
- みずほ銀行のコールセンターで使われる
 - 会話の内容から解答をオペレータに提示
- 三菱東京UFJ銀行ではLINEで提供しているQ&AサービスでWatsonを活用



AlphaGo, AlphaGo Zero, AlphaZero

- AlphaGo

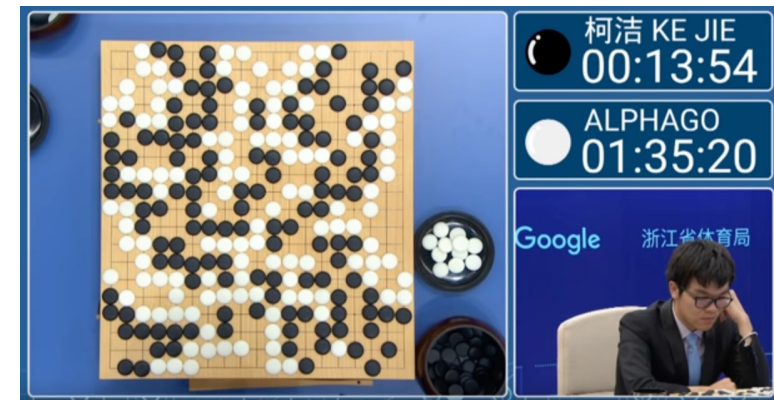
- 2016年イ・セドル氏に勝利, 2017年柯潔（コ・ジェ）氏に勝利
- 2015年まではアマ有段者レベルだった囲碁AIが, AlphaGoの登場によりにより囲碁AIが世界トップ棋士より強くなった.

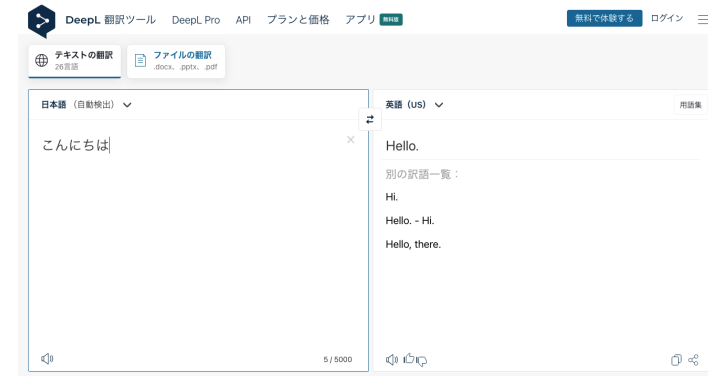
- AlphaGo Zero (Silver et al. 2017)

- 自己学習のみでAlphaGoに勝つ.

- AlphaZero (Silver et al. 2018)

- 様々なボードゲームにも対応できる.
- 自己学習のみで強くなる. 人間はデータを用意する必要がない.
- 碁ではAlpha Goにも勝てる.
- チェス (Stockfish), 将棋 (elmo) にも勝てる.





翻訳(DeepL)

(<https://www.youtube.com/watch?v=SGUCcjHTmGY>)

■ その他

- スパムメールの判定
- 天気予報と過去の販売実績から商品の仕入れ量を予測
- 自動車の衝突回避
- 画像から人だけ抜き取る
- 画像から不要なものを取り去る
- などなど、様々な場所で機械学習は活躍している.

機械学習の取り扱う問題

■ そもそもデータとはなにか


- 何かを文字や符号、数値などのまとまりとして表現したもの。
(IT用語辞典)
 - 人間にとって意味のあるものや、データを人間が解釈した結果のことを情報と呼ぶ。(IT用語辞典)
- 例：
 - 成績
 - 身体データ
 - 画像
 - 画像は色と場所の数値で出来ている。
 - 音声
 - 音声は時間と音の大きさの数値で出来ている。

成績		
名前	数学	英語
Aさん	75	80
Bさん	100	30


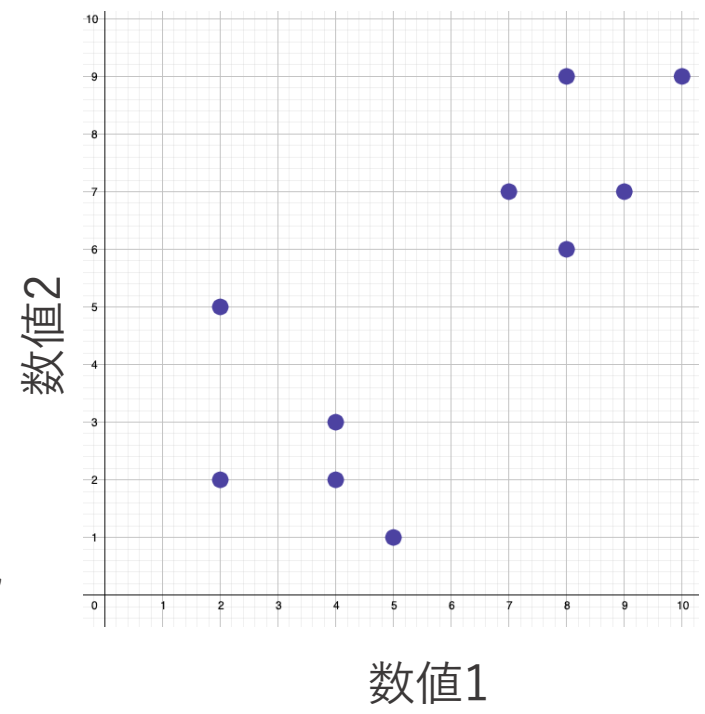
■ データには規則性があるかもしれない

データ

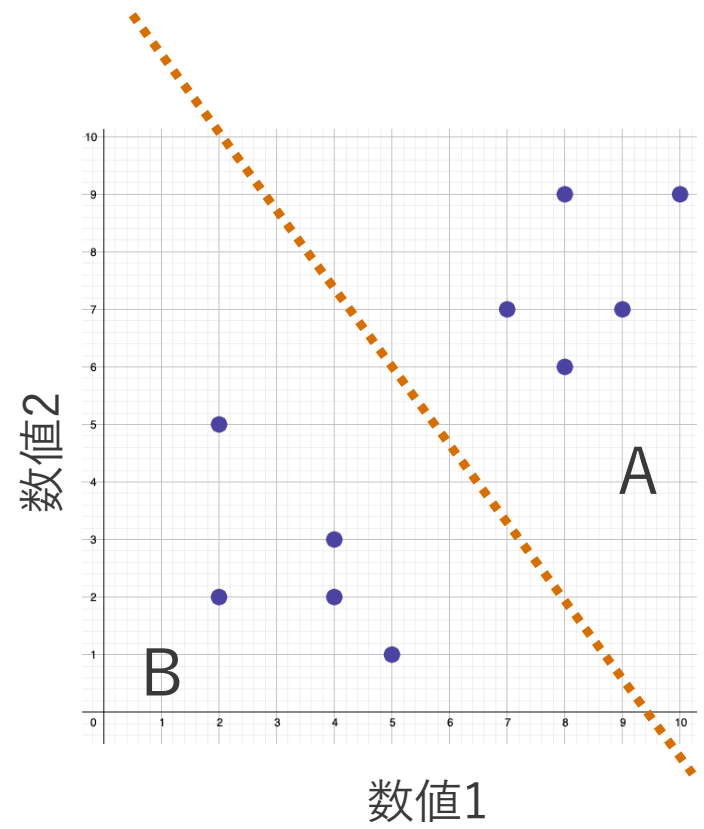
番号	ラベル	数値1	数値2
1	A	10	9
2	A	9	7
3	A	8	9
4	A	7	7
5	A	8	6
6	B	2	2
7	B	4	3
8	B	2	5
9	B	5	1
10	B	4	2



可視化



直線で分
けられる





可視化するとラベルAとラベルBの点（データ点）が直線で分けられる事がわかるが、コンピュータでこの直線を計算できないか？
ラベルがついていないデータが追加されたとき、自動でラベルをつけられないか？

■ データには規則性があるかもしれない

データ

番号	数値1	数値2
1	1	1.2
2	2	1.8
3	3	3.4
4	4	4.1
5	5	4.8
6	6	5.7
7	7	7.3
8	8	8.1
9	9	9
10	10	9.8



可視化すると数値 1 と数値 2 には比例関係がありそうだが、自動で直線の式を求められないか？
データから予測できないか？


■ データには規則性があるかもしれない

データ


番号	数学	英語
1	90	80
2	30	90
3	80	30
4	100	90
5	5	80
6	30	35
7	20	40
8	90	20
9	70	25
10	40	40



可視化



特徴が見える




可視化すると4つのグループがあるように見えるが、自動でこれらのグループを取り出せないか？

- データが多いと人間では無理
- 3次元以上では人間では無理
- とにかく人の手でやりたくない

機械学習が取り扱う問題

- 分類(Classification)


- ラベルの付いたデータを分ける.
- データを分ける線を引く.



分類

- 回帰(Regression)


- 値を予測する.
- データを再現できる関数を探す.



回帰

- クラスタリング(Clustering)

- データを塊ごとに分ける.



クラスタリング

- 強化学習(Reinforcement)

- 良さそうな行動を報酬に基づき手探りで探す.



どれが当たりやすいか
確かめながら探す


強化学習

学習の手法

機械学習で解く問題のおさらい

- 分類(Classification)


- データを分ける線を探す.
- データを分ける条件を探す.
- 分類する問題を識別問題という.



分類

- 回帰(Regression)


- データを再現できる関数を探す.



回帰

- クラスタリング(Clustering)

- データを塊ごとに分ける.



クラスタリング

- 強化学習(Reinforcement)

- 良さそうな行動を報酬に基づき手探りで探す.




どれが当たりやすいか
確かめながら探す

強化学習

識別問題と教師あり学習

識別問題



AグループとBグループに分けられたデータがある。
このデータを学習していない機械に入力したら、間違った分け方をするだろう。
機械が正しく分類するためには学習する必要がある。

■ 識別問題

1回目の学習




データ

A

ラベル




入力



学習中
の機械



学習



これはAだ

2回目の学習




データ

B

ラベル




入力



学習中
の機械



学習



これはBだ

3回目の学習




データ

A

ラベル




入力



学習中
の機械



学習



これはAだ

4回目の学習




データ

B

ラベル




入力



学習中
の機械



学習



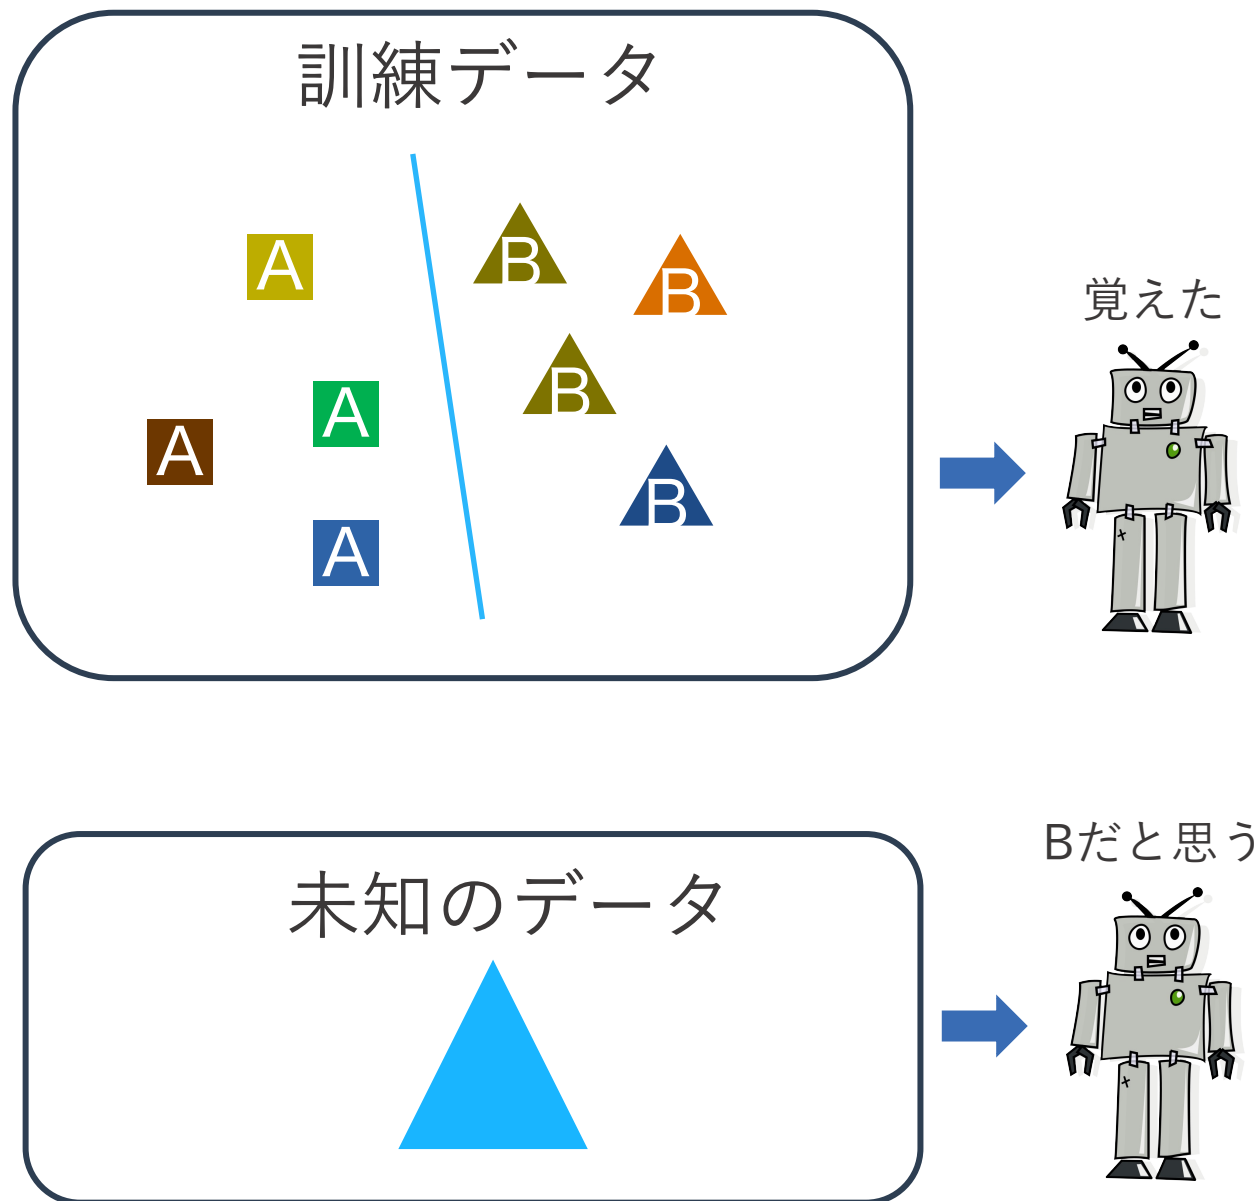
これはBだ

機械に分類結果がついたデータを与え，データと分類結果の関係（規則性）を学習させる。
ここでラベルとは機械に教える分類結果だと思ってほしい。

■ 識別問題

答えが分かっているデータ（ラベルが付いたデータ）を用い機械は学習する.

学習した結果, 機械は分類ルールを獲得する.
そして, 機械が未知のデータを判断する.


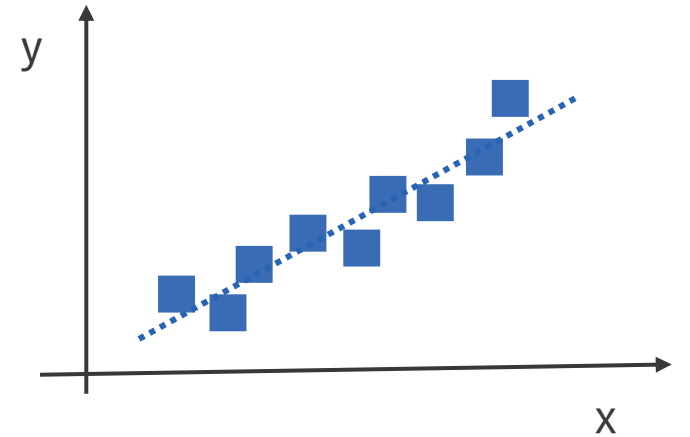


■ 教師あり学習

- このように，数値とラベルセットとなったデータを用い，機械が数値とラベルの関係を学ぶことを教師あり学習という．
- 教師あり学習では，数値とラベルがセットとなった学習用のデータ（訓練データ）が必要である．
- 機械の識別する能力（識別能力，識別性能）は，学習で用いなかったデータがどれだけ正確に識別できたかで測れる．

■ 回帰問題

- 数値 x と数値 y の組み合わせだったデータが有る.
- x と y の関係を見出し, x が未知の値の時の y の値を予測したい.
- 識別問題では入力にラベルをつけるが, 回帰問題では入力に対し数値を予測する.



■ 教師あり学習で用いられる手法

- k近傍法 (k nearest neighbor method)
- ロジスティック回帰 (logistic regression)
- 決定木 (decision tree)
 - ランダムフォレスト (random forest)
- サポートベクターマシン (support vector machine)
- 人工ニューラルネットワーク (artificial neural network)

教師なし学習

■ クラスタリング





人間は図のように分布しているデータを見た時、特に意識することなくデータ点の3つの塊を見つける事ができる。機械にも同じことをさせたい。

データ点の塊をクラスタといい、データをクラスタに分ける（クラスタを見つける）ことをクラスタリングという。

クラスタリングと分類の違いは、クラスタリングではラベルが必要ない点である。


■ クラスタリング




入力



人間




出力





データの塊を見つける。

おそらく、人間はデータ点同士が近ければ同じクラスタ、遠ければ別のクラスタだと無意識に判断している。この考え方（処理）を機械に導入すれば良い。



どうすれば人間のようにデータを分けられるのだろうか？


クラスタリング




入力



人間




出力



データの塊を見つける。

おそらく、人間はデータ点同士が近ければ同じクラスター、遠ければ別のクラスターだと無意識に判断している。この考え方（処理）を機械に導入すれば良い。

ただし、機械はクラスターの個数を見つけることが非常に苦手なのではじめに何個クラスターがあるか教えておく必要がある。



遠いと近いの違いが分かりません。
だから、クラスターが何個か分かりません。

■ クラスタリング

- クラスタリングとはデータをクラスタに自動で分けることをいう.
 - クラスタは近いデータ点同士の集まりである.
 - 近い遠いの基準には様々なものが用いられる.
 - 例：ユークリッド距離，コサイン距離
- クラスタリングの学習は，答えがついた訓練用のデータを必要としない.
- 答え（教師）が不要な学習を教師なし学習といい，クラスタリングは教師なし学習の典型例である.

■ 教師なし学習の例

- クラスタリング
- 次元削減
 - 高次元データを低次元データに変換すること.
 - 高次元データには次元の呪いと言われる様々な問題を抱えているため、データの次元を下げる事がある.

■ 教師なし学習の手法例

- クラスタリング
 - k-means法
 - 自己組織化マップ（人工ニューラルネットワーク）
- 次元削減
 - 主成分分析
 - 自己組織化マップ

強化学習

■ 強化学習とは

- 報酬が多い良い選択をすることが目的
- 答えは与えられていない
 - 報酬という手掛かりがある
 - 教師ありでもないし、教師なしでもない
- 試行錯誤で探す
 - 自分でデータ収集
 - とにかく探せば良いというわけではない

■ 強化学習の要素



エージェントは方策に従い行動し、報酬を受け取る。そして状態が変わる。

■ まとめ

- 教師あり学習
 - 教師となる答えが用意されている。
 - 機械は入力と答えの対応を学習する。
 - 人間の文字と発音の対応を覚えることに似ている。
- 教師なし学習
 - 教師となる答えがない。
 - 人間が似ている似ていないを判別することに似ている。
- 強化学習
 - 行動の良し悪しを決める報酬を多くするような行動を試行錯誤により学習する。
 - 運動を覚えることに似ている。